

LAPORAN UAS MACHINE LEARNING END-TO-END

SentimenID API: Klasifikasi Sentimen Teks Bahasa Indonesia

Nama : Panji Arya Soma
NIM : 1003240008
Program Studi : Informatika
Institusi : Institut Teknologi Tangerang Selatan
Mata Kuliah : Machine Learning
Kasus : Case C - Klasifikasi Sentimen Teks Bahasa Indonesia
Repository : github.com/panjiaryasoma/UAS-ML-1003240008
Tanggal : 26 Juli 2026

ABSTRAK

Proyek ini membangun sistem machine learning end-to-end untuk mengklasifikasikan teks Bahasa Indonesia ke dalam kelas negative, neutral, dan positive. Dataset IndoNLU SmSA berjumlah 12.260 baris berlabel. Audit kualitas data menemukan 81 exact duplicate, 45 baris dengan placeholder token, 103 baris dengan pemanjangan huruf, serta 346 teks sangat pendek. Setelah deduplikasi, 12.179 data dibagi secara stratified menjadi 9.743 data train dan 2.436 data test terkunci. Preprocessing menggunakan IndonesianTextNormalizer di dalam sklearn Pipeline untuk mempertahankan negasi, menormalkan variasi informal secara terbatas, dan menjaga konsistensi training-serving. Multinomial Naive Bayes, Logistic Regression, dan Calibrated Linear SVC dibandingkan melalui stratified 5-fold cross-validation menggunakan F1-macro. Calibrated Linear SVC memperoleh mean F1-macro 0,850229 dan dipilih sebagai model final. Evaluasi satu kali pada test set menghasilkan accuracy 0,889163, F1-macro 0,855483, F1-weighted 0,888721, dan log loss 0,312220. Pipeline disajikan melalui FastAPI dengan endpoint informasi, health check, dan prediksi. Sebanyak 40 automated test lulus, termasuk behavioral testing dan privacy-safe logging. Sistem layak sebagai baseline triage sentimen yang dapat direproduksi, tetapi masih terbatas pada negasi komposisional, sentimen campuran, sarkasme, perbedaan domain, dan kelas neutral.

Kata kunci: analisis sentimen, IndoNLU SmSA, TF-IDF, Calibrated Linear SVC, FastAPI, pytest, reproducibility

1. PENDAHULUAN

1.1 Latar Belakang

Media, marketplace, layanan publik, dan aplikasi digital menerima teks masukan dalam jumlah besar. Pengelompokan sentimen secara manual membutuhkan waktu, sulit diskalakan, serta rentan terhadap ketidakkonsistenan penilai. Pencocokan kata tunggal juga mudah gagal karena polaritas ditentukan oleh konteks, misalnya perbedaan antara “bagus”, “tidak bagus”, dan “tidak mengecewakan”.

Kasus C pada UAS meminta sistem klasifikasi teks Bahasa Indonesia minimal tiga kelas, representasi TF-IDF dengan n-gram, penanganan negasi atau kosakata informal, endpoint POST /predict-teks, dokumentasi sumber data dan lisensi, serta alur yang dapat dijalankan ulang dari repository bersih. Proyek SentimenID API disusun untuk memenuhi kebutuhan tersebut tanpa menambahkan komponen yang tidak diperlukan seperti dashboard, database, autentikasi, atau deployment cloud.

1.2 Rumusan Masalah

1. Bagaimana memperoleh dan mengaudit dataset sentimen Bahasa Indonesia yang sah, publik, bukan sintetis, dan dapat direproduksi?
2. Bagaimana menjaga preprocessing tetap konsisten serta mencegah data leakage selama cross-validation dan inferensi?
3. Model linear mana yang memberikan F1-macro terbaik di antara tiga kandidat yang dapat disajikan melalui API?
4. Bagaimana mengevaluasi generalisasi model secara disiplin pada test set yang dikunci?
5. Bagaimana menyediakan REST API, validasi input, automated testing, dan logging tanpa menyimpan teks mentah pengguna?

1.3 Tujuan dan Batasan

Tujuan utama proyek adalah menghasilkan baseline klasifikasi sentimen tiga kelas yang transparan, dapat diuji, dan dapat direproduksi. Sistem dimaksudkan untuk triage awal, bukan keputusan otomatis berisiko tinggi. Fine-tuning IndoBERT, dashboard, penyimpanan histori prediksi, cloud deployment, dan optimasi performa skala besar ditempatkan di luar ruang lingkup agar perhatian tetap pada integritas metodologi dan kontrak UAS.

Konvensi klaim

Skor cross-validation digunakan untuk pemilihan model, sedangkan test set hanya dibuka satu kali setelah konfigurasi dikunci. Temuan test set tidak digunakan untuk mengubah model. Dengan demikian, laporan membedakan bukti teknis, dukungan empiris, dan klaim yang belum dapat dibuktikan secara kausal.

2. DESAIN SISTEM DAN METODOLOGI

2.1 Alur End-to-End

Alur kerja dimulai dari pengunduhan data resmi, audit dan deduplikasi, stratified split, EDA train-only, normalisasi teks, representasi TF-IDF, perbandingan model dengan 5-fold cross-validation, evaluasi test set satu kali, serialisasi pipeline, serving FastAPI, serta pengujian otomatis. Setiap tahap menghasilkan artefak audit pada folder reports/ atau models/.

2.2 Pencegahan Data Leakage

Deduplikasi dilakukan sebelum split karena merupakan kurasi integritas baris, bukan transformasi yang mempelajari representasi. Setelah itu, test set dikunci. Normalizer dan TfidfVectorizer ditempatkan di dalam sklearn Pipeline sehingga keduanya di-fit ulang pada setiap fold cross-validation. Untuk kandidat Linear SVC, pipeline lengkap dibungkus oleh CalibratedClassifierCV agar normalizer dan TF-IDF juga dipelajari secara benar pada fold kalibrasi.

```
Data resmi -> audit & deduplikasi -> split 80:20
Train -> 5-fold CV -> model final -> refit seluruh
train
Test terkunci -> evaluate.py satu kali -> artefak
evaluasi
Pipeline tersimpan -> FastAPI -> automated tests
```

2.3 Reproducibility Contract

Seluruh proses dijalankan melalui modul Python, bukan notebook sebagai program utama. Random state dikunci pada 42. Runtime dan dependency dipin. Dataset, model, grafik, dan laporan dapat dibuat ulang melalui perintah README. Kontrak ini memastikan pengujian tidak bergantung pada langkah manual yang hanya diketahui pemilih proyek.

3. DATASET, SUMBER, DAN LISENSI


3.1 Dataset IndoNLU SmSA

Dataset final adalah IndoNLU SmSA (smsa_doc-sentiment-prosa) dari organisasi IndoNLP. File `train_preprocess.tsv` dan `valid_preprocess.tsv` diunduh oleh `src/load_data.py`, diverifikasi, lalu digabungkan menjadi 12.260 baris. Dataset mempunyai dua kolom: `text` sebagai fitur dan `label` sebagai target. Label terdiri atas `positive`, `negative`, dan `neutral`. Test resmi IndoNLU tidak digunakan karena labelnya disamarkan.

Informasi	Nilai
Baris awal	12.260
Jumlah kolom	2
Kolom fitur	text
Kolom target	label
Jumlah kelas	3
Missing text	0
Missing label	0

Tabel 1. Profil awal dataset sebelum kurasi.

3.2 Distribusi Kelas



Gambar 1. Distribusi label sentimen pada train set.

Kelas `positive` berjumlah 7.151 data atau 58,33%, `negative` 3.830 data atau 31,24%, dan `neutral` 1.279 data atau 10,43%. Ketimpangan ini menjadi alasan penggunaan `stratified split`, `stratified cross-validation`, dan `F1-macro` sebagai metrik utama. `Accuracy` tetap dilaporkan sebagai metrik sekunder, tetapi tidak digunakan sebagai satu-satunya dasar pemilihan model.

3.3 Lisensi dan Atribusi

Dataset card benchmark IndoNLU mencantumkan lisensi MIT, sedangkan repository dan code upstream menggunakan Apache License 2.0 berdasarkan file LICENSE. Laporan dan README memisahkan kedua lingkup tersebut agar tidak menyamakan lisensi data dengan lisensi repository. Atribusi lengkap disimpan dalam `DATASET_ATTRIBUTION.md`, sedangkan repository proyek menyertakan file LICENSE.

Sumber canonical

https://github.com/IndoNLP/indonlu/tree/master/dataset/smsa_doc-sentiment-prosa


4. EXPLORATORY DATA ANALYSIS DAN KUALITAS DATA

4.1 Audit Wajib

Audit memeriksa missing value, teks kosong, duplikasi, konflik label, spasi tidak wajar, nilai mirip unknown, placeholder token, pemanjangan huruf, teks sangat pendek, URL, mention, dan hashtag. Pemeriksaan diperluas agar tiga kekotoran yang dilaporkan benar-benar ditemukan dalam data, bukan direkayasa untuk memenuhi rubric.

Indikator	Jumlah
Exact duplicate rows	81
Duplicate text rows	151
Duplicate text groups	70
Conflicting label rows	0
Placeholder token	45
Elongated-word rows	103
Teks <= 2 kata	346
Missing / blank text	0

Tabel 2. Ringkasan audit kualitas data.



Gambar 2. Jumlah nilai hilang pada kolom `text` dan `label`.

Grafik menunjukkan bahwa kolom `text` dan `label` tidak memiliki missing value. Karena itu, imputasi tidak diperlukan. Pemeriksaan tetap dipertahankan sebagai bukti audit sebelum modeling, bukan dihilangkan hanya karena hasilnya nol.

4.2 Tiga Kekotoran Utama dan Tindakan

Temuan	Tindakan	Alasan
81 exact duplicate	Dihapus sebelum split	Mencegah teks identik tersebar pada train dan test.
45 placeholder token	Dipertahankan dan dinormalisasi	Token seperti <code>_laugh_</code> dapat membawa informasi emosi.
103 pemanjangan huruf	Dinormalisasi terbatas	Mengurangi fragmentasi vocabulary tanpa menghapus penekanan secara agresif.

Tabel 3. Tindakan kurasi terhadap kekotoran data nyata.

Sebanyak 346 teks dengan panjang maksimal dua kata tidak dihapus. Teks pendek seperti “tidak bagus”, “sangat kecewa”, atau “enak banget” tetap mempunyai sinyal sentimen. Tidak ditemukan konflik label, sehingga tidak diperlukan aturan arbiter untuk memilih label. Tidak terdapat missing value standar, sehingga imputasi tidak diperlukan.


4.3 Split Modeling

```
train_test_split(  
    modeling_df,  
    test_size=0.2,  
    stratify=modeling_df["label"],  
    random_state=42,  
)
```

Partisi	Jumlah
Data setelah deduplikasi	12.179
Train set	9.743
Test set terkunci	2.436

Tabel 4. Partisi data modeling.


4.4 Interpretasi Grafik EDA



Gambar 3. Panjang teks per label pada train set.

Kelas positive mempunyai median dan variasi panjang teks yang lebih besar, sedangkan neutral cenderung lebih pendek. Distribusi ketiga kelas tetap tumpang tindih, sehingga panjang teks tidak digunakan sebagai fitur sentimen tersendiri. Temuan ini menjadi dasar pemeriksaan khusus terhadap teks sangat pendek dan teks panjang dengan sentimen campuran pada error analysis.

4.5 Istilah Teratas dan Implikasi N-gram



Gambar 4. Istilah teratas pada kelas negative, neutral, dan positive.

Kata “tidak” mendominasi kelas negative, tetapi juga muncul pada neutral dan positive. Kelas positive banyak memuat kata “anak”, “tempat”, “makanan”, dan “makan”, sedangkan neutral memuat istilah informasional dan politik seperti “demokrat”, “pilkada”, “partai”, dan “jakarta”. Kemunculan negasi pada lebih dari satu kelas menunjukkan unigram saja tidak cukup; konteks lokal seperti “tidak bagus” dan “tidak mengecewakan” memerlukan bigram.

4.6 Prakiraan Sebelum Training

1. TF-IDF unigram dan bigram diperkirakan membantu membedakan pola negasi dibandingkan unigram saja.
2. Kelas neutral diperkirakan menjadi kelas paling sulit karena jumlahnya paling sedikit dan batas leksikalnya kurang tegas.
3. Normalisasi informal terbatas diperkirakan mengurangi fragmentasi vocabulary, tetapi normalisasi agresif dapat merusak sinyal sentimen.

5. PREPROCESSING TEKS

5.1 IndonesianTextNormalizer

Preprocessing diimplementasikan sebagai custom transformer yang mewarisi BaseEstimator dan TransformerMixin. Method fit tidak mempelajari statistik data, sedangkan transform menerima list, pandas Series, DataFrame satu kolom, dan NumPy array satu kolom. DataFrame multi-kolom ditolak untuk mencegah input ambigu. Class telah diuji melalui pickle dan joblib round trip agar pipeline dapat dimuat oleh FastAPI.

Aturan	Contoh / Tujuan
Lowercase	MAKANAN ENAK -> makanan enak
Whitespace	Trim dan gabungkan spasi berulang
Placeholder	laugh -> laugh; token tidak dihapus
Pemajangan huruf	enaaak -> enak; mantapppp -> mantap
Slang negasi	enggak, nggak, ngga, gak, ga, gk, tdk -> tidak
Negasi formal	tidak, bukan, belum tetap dipertahankan
Missing-like input	None, NaN, pd.NA -> string kosong

Tabel 5. Aturan utama IndonesianTextNormalizer.

5.2 Keputusan Tidak Menggunakan Stemming dan Stopword Removal

Stopword removal tidak digunakan dalam modeling. Daftar stopwords hanya dipakai untuk visualisasi istilah teratas. Kata negasi sengaja tidak dihapus karena berpotensi membalik polaritas. Stemming dan pembersihan agresif juga dihindari karena dapat merusak konteks, mengubah kata valid, atau menghapus penekanan emosional. Prinsipnya adalah normalisasi minimum yang didukung oleh temuan data.

5.3 Pipeline Konsisten

```
IndonesianTextNormalizer
-> TfidfVectorizer
-> classifier
```

Penempatan seluruh transformasi dalam pipeline memastikan training, cross-validation, evaluasi, dan serving memakai aturan yang sama. Endpoint API tidak mengulang preprocessing secara manual. Desain ini mengurangi training-serving skew dan membuat artefak model dapat diaudit sebagai satu unit.

Batas klaim preprocessing

Normalizer terbukti bekerja secara teknis dan kompatibel dengan pipeline. Kontribusinya terhadap kenaikan F1-macro belum dapat dipisahkan secara kausal karena tidak dilakukan ablation study antara pipeline dengan dan tanpa normalizer.

6. TRAINING DAN PEMILIHAN MODEL

6.1 Kandidat dan Kontrak Cross-Validation

Tiga algoritma dibandingkan pada 9.743 data train: Multinomial Naive Bayes, Logistic Regression, dan Calibrated Linear SVC. Seluruh kandidat dapat menghasilkan probabilitas kelas. Model selection menggunakan StratifiedKFold lima fold, shuffle=True, random state=42, dan scoring F1-macro. Kandidat SVC menggunakan kalibrasi sigmoid tiga fold.

Komponen	Konfigurasi
Metrik utama	F1-macro
Cross-validation	StratifiedKFold, 5 fold
Shuffle / random state	True / 42
TF-IDF	Kandidat unigram dan unigram-bigram
Kalibrasi SVC	Sigmoid, 3-fold
Class weighting	Balanced untuk model linear

Tabel 6. Kontrak eksperimen training.

6.2 Hasil Cross-Validation

Model	Mean F1	Std	Waktu
Calibrated Linear SVC	0,850229	0,009328	10,634 dtk
Logistic Regression	0,847877	0,007200	6,799 dtk
Multinomial Naive Bayes	0,754436	0,014869	7,974 dtk

Tabel 7. Hasil terbaik setiap kandidat model.

Calibrated Linear SVC memperoleh mean F1-macro tertinggi. Selisih terhadap Logistic Regression hanya 0,002352 atau sekitar 0,235 poin persentase, sehingga kemenangan tersebut dicatat sebagai perbedaan tipis. Logistic Regression mempunyai standard deviation lebih rendah dan sedikit lebih stabil antar-fold, tetapi aturan seleksi yang dikunci sebelumnya memprioritaskan skor rata-rata tertinggi.

6.3 Parameter Terbaik

Model	Parameter terbaik
Calibrated Linear SVC	C=0,5; ngram=(1,2); class_weight=balanced; sigmoid cv=3
Logistic Regression	C=2,0; ngram=(1,2); class_weight=balanced; max_iter=2000
Multinomial NB	alpha=0,5; ngram=(1,1)

Tabel 8. Konfigurasi terbaik hasil pencarian parameter.

6.4 Artefak Training

- models/model.joblib berisi CalibratedClassifierCV yang membungkus pipeline normalizer, TF-IDF, dan LinearSVC.
- models/metadata.json mencatat versi model, waktu training, dataset, runtime, konfigurasi split, parameter terbaik, dan urutan kelas.
- reports/model_selection_results.csv menyimpan skor terbaik setiap kandidat untuk audit tanpa training ulang.

7. EVALUASI FINAL

7.1 Disiplin Penggunaan Test Set

Test set 2.436 baris baru dibuka setelah kandidat, parameter, normalizer, TF-IDF, dan model final dikunci. Status evaluasi dicatat sebagai `evaluated_once`. Test set tidak dipakai untuk memperbaiki model, memilih threshold, atau mengubah preprocessing. Pendekatan ini menjaga hasil final sebagai estimasi generalisasi yang terpisah dari proses model selection.

7.2 Metrik Utama

Metrik	Nilai
Accuracy	0,889163
F1-macro	0,855483
F1-weighted	0,888721
Log loss	0,312220
Prediksi benar	2.166
Prediksi salah	270

Tabel 9. Metrik evaluasi final pada test set.

F1-macro test sebesar 0,855483 sedikit lebih tinggi daripada mean cross-validation 0,850229, dengan selisih +0,005254. Selisih kecil tersebut menunjukkan konsistensi antara estimasi CV dan test set; tidak ditemukan performance collapse. Namun, hasil ini tidak membuktikan model bebas dari seluruh bentuk overfitting.


7.3 Performa per Kelas

Kelas	Precision	Recall	F1	Support
Negative	0,859230	0,851316	0,855254	760
Neutral	0,805785	0,767717	0,786290	254
Positive	0,918806	0,931083	0,924904	1.422

Tabel 10. Classification report per kelas.

Positive memperoleh performa terbaik, dengan recall 0,931083 dan F1-score 0,924904. Neutral memiliki recall 0,767717 dan F1-score 0,786290, terendah di antara tiga kelas. Dari 254 data neutral, 195 diprediksi benar, sedangkan 59 data atau 23,23% salah diklasifikasikan. Jumlah data neutral yang lebih sedikit dan batas leksikal yang kabur berkontribusi pada kesulitan tersebut.

7.4 Confusion Matrix



Gambar 5. Confusion matrix pada test set.

Kesalahan tunggal terbesar adalah negative diprediksi positive sebanyak 87 kasus. Arah sebaliknya terjadi pada 77 kasus. Neutral diprediksi negative 29 kali dan positive 30 kali. Secara agregat distribusi prediksi dekat dengan distribusi aktual, tetapi model sedikit lebih sering memilih positive dan sedikit lebih jarang memilih neutral.

8. ERROR ANALYSIS DAN EVALUASI PRAKIRAAN

8.1 Analisis Lima Worst Errors

Lima kasus berikut dipilih dari prediksi salah dengan confidence tertinggi pada reports/error_analysis.csv. Pemilihan ini tidak mengklaim bahwa kelimanya paling representatif, tetapi menyoroti kondisi ketika model salah dengan keyakinan sangat tinggi.

1. Negative -> Positive (confidence 0,989383). Cuplikan: "...dagingnya enak... banyak pilihan... pelayanan sering buruk dan mengecewakan...". Banyak token positif pada makanan mendominasi keluhan pelayanan yang menentukan label akhir.
2. Negative -> Positive (confidence 0,986408). Cuplikan: "tidak mantap". Token mantap merupakan sinyal positive yang kuat; fitur bigram belum cukup membalik keputusan model.
3. Negative -> Positive (confidence 0,985519). Cuplikan: "tempatnya nyaman... tapi rasa makanan tidak semewah harganya... overpriced". Pujian suasana menutupi kritik rasa dan harga.
4. Negative -> Positive (confidence 0,982953). Cuplikan: "suasana resto sangat santai dan nyaman... rasa rata-rata mendekati tidak enak". Model tidak memberi prioritas pada bagian evaluatif setelah kontras.
5. Positive -> Negative (confidence 0,976750). Cuplikan: "...sabotase jelas di luar konteks ajaran islam... islam itu rahmatan lil alamin". Kosakata konflik mendorong shortcut negative walaupun sikap keseluruhan diberi label positive.

Kelima kasus menunjukkan tiga batas utama. Pertama, TF-IDF tidak memodelkan urutan global dan tidak memahami bahwa kesimpulan setelah kata kontras dapat lebih penting. Kedua, negasi komposisional tidak selalu selesai hanya dengan bigram. Ketiga, model dapat menggunakan shortcut leksikal berbasis domain. Karena itu, confidence harus dibaca sebagai keyakinan statistik model, bukan kepastian makna.

8.2 Pola Kesalahan Utama

- Negasi komposisional: "tidak mantap" seharusnya negative, sedangkan "tidak mahal" dan "tidak malas" dapat berarah positive. Dampak negasi bergantung pada kata setelahnya.
- Sentimen campuran dan kontras: kata pujian di awal dapat mendominasi keluhan di akhir karena TF-IDF tidak memodelkan urutan global atau prioritas kesimpulan.

- Ambiguitas label: beberapa teks mempunyai sinyal yang dapat diperdebatkan. Hal ini hanya dicatat sebagai kemungkinan noise, bukan bukti bahwa label asli salah.
- Perbedaan domain: ulasan restoran, komentar politik, telekomunikasi, dan topik lain menggunakan kosakata polar secara berbeda.
- Kelas neutral: teks factual dapat memuat kata polar tanpa mengekspresikan sentimen utama sehingga batasnya tidak cukup ditentukan oleh ketiadaan kata positif atau negatif.

8.3 Evaluasi Tiga Prakiraan Awal

Prakiraan	Status	Bukti
Neutral paling sulit	Terkonfirmasi	F1 0,786290 dan recall 0,767717 merupakan yang terendah.
Bigram membantu negasi	Didukung, tidak kausal	Dua model terbaik memilih ngram=(1,2), tetapi beberapa negasi tetap gagal.
Normalisasi informal membantu	Belum terbukti kausal	Normalizer bekerja, tetapi tidak ada ablation study tanpa normalizer.

Tabel 12. Status prakiraan setelah evaluasi final.

9. IMPLEMENTASI REST API

9.1 Arsitektur Serving

FastAPI berfungsi sebagai lapisan inferensi untuk pipeline final. Pada startup, aplikasi memuat model.joblib, metadata.json, dan urutan kelas melalui lifespan. Objek tersebut disimpan dalam app.state dan digunakan kembali oleh setiap request. Model tidak dimuat ulang dan tidak dilatih ulang ketika endpoint dipanggil.

Method	Endpoint	Fungsi
GET	/	Informasi layanan dan lokasi dokumentasi
GET	/health	Status layanan, model_loaded, dan model_version
POST	/predict-teks	Prediksi label, confidence, probabilitas kelas, versi model

Tabel 13. Kontrak endpoint SentimenID API.

9.2 Request dan Response

```
POST /predict-teks
{
  "text": "aplikasinya tidak bagus dan sering error",
  "language": "id"
}

{
  "prediction": "negative",
  "confidence": 0.639703,
  "probabilities": {
    "negative": 0.639703,
    "neutral": 0.007034,
    "positive": 0.353263
  },
  "model_version": "sentimenid-20260725T181613Z"
}
```

Respons menyertakan seluruh probabilitas agar pengguna dapat membedakan prediksi kuat dan ambigu. Pada contoh negatif, probabilitas positive masih sekitar 0,353 karena token “bagus” tetap mempunyai sinyal kuat walaupun bigram “tidak bagus” tersedia. API tidak menyembunyikan ketidakpastian tersebut.

9.3 Validasi Input

Schema Pydantic mewajibkan field text dan language. Teks kosong, field hilang, payload dengan tipe data salah, atau language selain id menghasilkan HTTP 422 sebelum inferensi. Pembatasan bahasa sesuai dengan data training dan mencegah klaim dukungan multi-bahasa yang belum diuji.

9.4 Konsistensi Training-Serving

Endpoint mengirim teks asli langsung ke pipeline tersimpan. Lowercase, whitespace normalization, slang mapping, TF-IDF, dan klasifikasi tidak diulang di app/main.py. Test khusus memverifikasi kontrak tersebut. Dengan demikian, perubahan normalizer cukup

dilakukan pada satu sumber dan risiko perbedaan preprocessing antara eksperimen dan API berkurang.

10. PRIVACY-SAFE LOGGING

Logging ditambahkan untuk observabilitas dan audit operasional dengan prinsip minimisasi data. Setiap prediksi mencatat timestamp UTC, latency, panjang teks, kode bahasa, label prediksi, confidence, dan versi model. Isi teks mentah pengguna tidak dicatat. Desain ini mempertahankan informasi yang diperlukan untuk monitoring tanpa membuat salinan tersembunyi dari konten pengguna.

prediction_completed timestamp_utc=<timestamp> latency_ms=<nilai> text_length=<jumlah karakter> language=id prediction=<label> confidence=<nilai> model_version=<versi>	
Field log	Kegunaan
timestamp_utc	Urutan waktu dan audit kejadian
latency_ms	Monitoring performa inferensi
text_length	Analisis ukuran input tanpa menyimpan isi
language	Verifikasi kontrak bahasa
prediction / confidence	Monitoring distribusi hasil dan keyakinan
model_version	Traceability artefak model

Tabel 14. Metadata prediction log.

Pengujian menggunakan caplog untuk menangkap record logging, memastikan seluruh metadata tersedia, dan memastikan teks khusus yang dikirim test tidak muncul pada log. Kontrak privasi ini dinyatakan lulus melalui tests/test_logging.py.

11. PENGUJIAN OTOMATIS

11.1 Struktur Test Suite

File	Ruang lingkup
test_load_data.py	Unduh, schema, label, dan sumber data
test_edu.py	Audit, deduplikasi, split, dan grafik
test_transformers.py	Aturan normalisasi, bentuk input, serialisasi
test_train.py	Kandidat, CV, parameter, dan artefak training
test_evaluate.py	Metrik, probabilitas, report, dan error analysis
test_api.py	Endpoint 200/422, schema, lifespan, pipeline
test_behavior.py	Arah probabilitas negasi serta keluhan vs pujian
test_logging.py	Metadata log dan larangan raw text

Tabel 15. Cakupan test suite.

11.2 Mechanical dan Behavioral Testing

Mechanical test memastikan program memenuhi kontrak teknis: health mengembalikan 200, model dimuat satu kali, response mempunyai label dan probabilitas, request invalid menghasilkan 422, serta pipeline tersimpan digunakan langsung. Behavioral test menilai hubungan semantik dasar yang tidak cukup dibuktikan oleh status endpoint atau schema.

Test 1 - Negation shift. Kalimat pujian dibandingkan dengan versi serupa yang diberi negasi. Assertion mewajibkan probabilitas negative pada versi bernegasi meningkat. Test tidak mengunci label atau angka confidence tertentu agar tetap sensitif terhadap regresi perilaku tanpa menjadi rapuh setelah retraining.

Test 2 - Complaint vs praise. Keluhan eksplisit dibandingkan dengan pujian eksplisit. Assertion mewajibkan probabilitas negative pada keluhan lebih tinggi daripada pada pujian. Hubungan ini memastikan model membedakan dua input dengan polaritas berlawanan secara masuk akal.

Hasil behavioral testing

Dua	behavioral	test	lulus:
test_negation_moves_probability_toward_negative			dan
test_complaint_has_higher_negative_probability_than_praise.			
Hasil akhir adalah 2 passed dan 0 failed.			

11.3 Hasil Akhir

Metrik	Nilai
Total test	40
Passed	40
Failed	0

Metrik	Nilai
Kelulusan	100%
Warnings	33
Durasi	sekitar 4,10 detik

Tabel 16. Ringkasan hasil automated testing.

Warning yang muncul adalah DeprecationWarning internal joblib ketika menangani NumPy 2.5. Warning tidak menyebabkan load model gagal, schema berubah, probabilitas tidak valid, atau test gagal. Karena dependency telah dipin dan seluruh test lulus, warning dicatat sebagai risiko kompatibilitas yang perlu dipantau, bukan defect fungsional aplikasi.

12. REPRODUKSIBILITAS DAN REPOSITORY

12.1 Struktur Repository

Repository menggunakan struktur src/, app/, tests/, data/, models/, reports/, requirements, README, lisensi, dan atribusi dataset. Program utama berada pada modul Python sehingga setiap tahap dapat dijalankan dari terminal. Data dan artefak biner model dapat dibuat ulang dari instruksi README; metadata, laporan, grafik, dan kode disimpan sebagai bukti audit.

```
python -m src.load_data
python -m src.eda
python -m src.train
python -m src.evaluate
python -m pytest tests/ -q
python -m uvicorn app.main:app --reload
```

12.2 Environment yang Diuji

Komponen	Versi
Python	3.12.7
NumPy	2.5.1
pandas	3.0.5
scikit-learn	1.9.0
Matplotlib	3.11.1
joblib	1.5.3
pytest	9.1.1
FastAPI	0.140.0
Uvicorn	0.51.0
Pydantic	2.13.4
httpx2	2.7.0

Tabel 17. Dependency yang telah diuji dan dipin.

Konsistensi versi terutama penting untuk scikit-learn, NumPy, dan joblib karena artefak serialisasi dapat sensitif terhadap perbedaan runtime. Requirements training/testing dipisahkan dari requirements serving, tetapi requirements-api.txt memanggil requirements.txt agar instalasi lengkap dapat dilakukan dengan satu perintah.

12.3 Git dan GitHub

Repository publik tersedia pada github.com/panjiaryasoma/UAS-ML-1003240008. Branch main lokal telah disinkronkan dengan origin/main dan working tree berada dalam kondisi clean setelah push. Riwayat commit memisahkan behavioral test, privacy-safe logging, testing findings, dependency pin, dan README reproducibility agar perubahan dapat diaudit.

13. KETERBATASAN DAN PENGEMBANGAN LANJUT

- Distribusi kelas tidak seimbang; neutral hanya sekitar 10% data dan mempunyai performa terendah.
- TF-IDF tidak memahami urutan global, ironi, implikatur, sarkasme, atau hubungan kontras yang panjang.
- Bigram hanya menyediakan konteks lokal dua token dan tidak menyelesaikan seluruh negasi komposisional.
- Tidak ada ablation study untuk mengukur kontribusi independen normalizer.
- Probabilitas telah dikalibrasi, tetapi belum diuji menggunakan reliability diagram atau expected calibration error.
- Belum ada evaluasi lintas-dataset, out-of-domain, input adversarial, beban tinggi, atau concurrent requests.

- API belum mempunyai autentikasi, rate limiting, batch prediction, mekanisme abstain, atau deployment publik.
- Sebagian teks atau label tampak ambigu, tetapi proyek tidak melakukan relabeling manual.

Pengembangan lanjutan dapat mencakup character n-gram, negation scope, ablation study, evaluasi kalibrasi, dataset eksternal, mekanisme abstain untuk confidence rendah, serta model kontekstual seperti IndoBERT. Eksperimen lanjutan harus memakai validation set atau dataset baru karena test set final telah digunakan satu kali.

14. KESIMPULAN

SentimenID API berhasil membangun pipeline machine learning end-to-end untuk klasifikasi sentimen Bahasa Indonesia yang dapat direproduksi dan diaudit. Dataset publik telah diverifikasi, 81 exact duplicate dihapus sebelum split, placeholder dan pemanjangan huruf ditangani secara proporsional, serta preprocessing ditempatkan dalam pipeline untuk mencegah leakage dan training-serving skew.

Calibrated Linear SVC dipilih melalui stratified 5-fold cross-validation dengan mean F1-macro 0,850229. Evaluasi satu kali pada 2.436 test set menghasilkan accuracy 0,889163 dan F1-macro 0,855483. Kelas positive mempunyai performa terbaik, sedangkan neutral menjadi kelas tersulit. Error analysis menunjukkan keterbatasan utama pada negasi komposisional, sentimen campuran, teks lintas-domain, dan shortcut leksikal.

FastAPI menyediakan endpoint informasi, health, dan prediksi dengan probabilitas serta versi model. Request invalid ditolak dengan HTTP 422. Privacy-safe logging mencatat metadata operasional tanpa menyimpan teks mentah. Seluruh 40 automated test lulus. Berdasarkan bukti tersebut, sistem memenuhi ruang lingkup akademik sebagai baseline triage sentimen, tetapi hasilnya tetap memerlukan interpretasi dan pemeriksaan manusia untuk keputusan penting.

15. MATRIKS PEMENUHAN REQUIREMENT

Requirement	Status	Bukti utama
Dataset publik ≥ 1.000 baris, 3 kelas	Terpenuhi	IndoNLU SmSA, 12.260 baris, positive/negative/neutral
Struktur repository wajib	Terpenuhi	src, app, tests, data, models, reports, requirements, README
Load data dan profil schema	Terpenuhi	src/load_data.py dan dokumentasi Gambar A2
Minimal empat grafik EDA	Terpenuhi	Distribusi label, missing value, panjang teks, istilah teratas
Minimal tiga kekotoran nyata	Terpenuhi	Duplicate, placeholder token, pemanjangan huruf
TF-IDF, n-gram, negasi/informal	Terpenuhi	TfidfVectorizer (1.2) dan IndonesianTextNormalizer
Tiga model dan 5-fold CV	Terpenuhi	MNB, Logistic Regression, Calibrated Linear SVC
Pipeline utuh disimpan	Terpenuhi	models/model.joblib dan metadata.json
Evaluasi final dan confusion matrix	Terpenuhi	F1-macro 0,855483; reports/confusion_matrix.png
POST /predict-teks dan validasi	Terpenuhi	HTTP 200 untuk valid, HTTP 422 untuk invalid
Automated dan behavioral testing	Terpenuhi	40 passed; negasi dan keluhan vs pujian
README dari nol dan dependency pin	Terpenuhi	README.md, requirements.txt, requirements-api.txt
Repository GitHub sinkron	Terpenuhi	origin/main, working tree clean, Gambar A10

Tabel 18. Matriks pemenuhan requirement proyek UAS.

15.1 Daftar Artefak Final

Artefak	Fungsi
models/model.joblib	Pipeline inferensi lengkap
models/metadata.json	Versi, runtime, split, parameter, dan kelas
reports/model_selection_results.csv	Audit hasil cross-validation
reports/evaluation_summary.json	Ringkasan metrik evaluasi final
reports/classification_report.csv	Precision, recall, F1, dan support
reports/confusion_matrix.png	Visualisasi kesalahan antar-kelas
reports/error_analysis.csv	Kesalahan confidence tinggi untuk audit
reports/test_predictions.csv	Seluruh prediksi dan probabilitas test
reports/*_findings.md	Interpretasi setiap tahap
README.md	Reproduksi proyek dari clone bersih


Tabel 19. Artefak final dan fungsi auditnya.

REFERENSI


- [1] B. Wilie et al., “IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding,” Proceedings of AACL-IJCNLP, 2020.
- [2] IndoNLP, “IndoNLU - SmSA Dataset,” https://github.com/IndoNLP/indonlu/tree/master/dataset/smsa_doc-sentiment-prosa, diakses Juli 2026.
- [3] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.
- [4] S. Ramírez, “FastAPI Documentation,” <https://fastapi.tiangolo.com/>, diakses Juli 2026.
- [5] P. A. Soma, “UAS-ML-1003240008: SentimenID API,” <https://github.com/panjiaryasoma/UAS-ML-1003240008>, 2026.

LAMPIRAN A. DOKUMENTASI EKSEKUSI


Lampiran menampilkan bukti visual terpilih dari proses aktual. Screenshot digunakan sebagai dokumentasi pendukung, sedangkan angka dan interpretasi utama tetap ditulis dalam tabel serta pembahasan laporan. Gambar kegagalan karena typo atau posisi folder yang salah tidak dimasukkan karena tidak membuktikan pemenuhan kontrak proyek.




Gambar A1. Struktur repository pada VS Code.




Gambar A3. Ringkasan audit kekotoran data dan split modeling.




Gambar A2. Profil dataset, distribusi target, dan deteksi exact duplicate.




Gambar A4. Eksekusi training, hasil 5-fold CV, dan model terpilih.



Gambar A5. Evaluasi final dan classification report pada test set terkunci.



Gambar A7. Request valid menghasilkan HTTP 200 dan prediksi positive.




Gambar A9. Seluruh 40 automated test lulus, termasuk behavior dan logging.



Gambar A6. Swagger UI dengan endpoint system dan prediction.



Gambar A8. Validasi language selain id menghasilkan HTTP 422.



Gambar A10. Push ke GitHub, sinkronisasi origin/main, dan riwayat commit.

LAMPIRAN B. ASAL ARTEFAK GAMBAR

Seluruh grafik data dalam laporan memakai file asli hasil eksekusi proyek: label_distribution.png, missing_values_by_column.png, text_length_by_label.png, top_terms_by_label.png, dan confusion_matrix.png. Grafik turunan yang tidak disimpan oleh script proyek tidak digunakan. Diagram rancangan tambahan juga tidak dimasukkan ke badan laporan apabila urutan prosesnya tidak identik dengan implementasi aktual. Caption hanya menjelaskan isi gambar tanpa menambahkan klaim sumber yang tidak diperlukan.

Gambar dalam laporan	File artefak proyek
Distribusi label sentimen	reports/label_distribution.png
Jumlah nilai hilang per kolom	reports/missing_values_by_column.png
Panjang teks per label	reports/text_length_by_label.png
Istilah teratas per kelas	reports/top_terms_by_label.png
Confusion matrix test set	reports/confusion_matrix.png

Tabel B1. Pemetaan gambar terhadap artefak asli repository.